

폐암 예측 모델과 적용

- 간단한 폐암 진단 : 병원에 가지 않고 AI로 쉽게 폐암을 진단한다 -

2023년 1월

자카르타 한국 국제학교

남상혁, 문주원

국문초록

주제어: 암, 흡연, 폐암, 예측, 인공지능(AI) - 딥러닝, 선형회귀

해가 지나면 지날수록, 국내에서는 점점 암의 환자 수가 늘어나고 있다. 국립암센터 통계 결과에 따르면 1999년에는 국내 암 환자수가 10만1847명이었던 것에 반해, 지난해인 2021년도에는 국내 암 환자수가 25만4718명으로 약 2.5배 넘게 증가한 것을 알수있다. 특히 그중에서도 점점 환자의 수가 꾸준히 늘고 있고, 가장 많은 사람들이 걸리는 폐암은 작년에는 국내에서 10만2843명의 환자가 있었는데, 올해는 11만376명으로 전년 대비 7.3%나 늘었는 것을 확인할 수 있다. 이 폐암은 다른 암과 마찬가지로 초기에는 증상이 눈에 띄지 않아 구분하기 어렵지만, 우리나라 국민 10명중 4명은 암에 걸리는 것을 확인 할 수 있고, 그중에서도 18%가 폐암에 걸릴정도로 많은 사람들이 앓고 있는 질환인 것을 알수 있다. 우리는 누구나 뉴스나 기사, 아니면 주위 사람들을 통해 암의 위험성에 대해 인지를 하고 있지만, 정작 대부분의 사람들은 자신이 암에 걸리면 그 증상이 심해질 때까지 자신이 암인지에 대해 인지를 하지 못하고 있는 데, 이것은 매우 위험하다. 특히 그런 암들중에서도 우리는 사람들이 가장 많이 걸리는 폐암에 대해 논문을 써 내려갈 것이다. 폐암은 초기에는 일반 감기나 결핵, 폐암과 같은 증상으로 자신이 폐암에 걸렸다는 것을 확실하고 제대로 인지하지 못하지만 이것을 계속 방치하게 될 경우 날이 지날때마다 점점 사망률이 오르는 것을 확인할 수 있다. 특히 폐암을 오랫동안 방치하여 4기까지 가게되면 뇌나 식도같이 폐와 가까운 기관에도 암이 전이될수도 있고, 그러면 거의 사망하기 때문에 평소에 흡연을 하지 않는 것과 같이 각별한 주의가 필요하고, 정기적인 건강검진이나 증상이 있으면 병원을 바로 가보아서 폐암을 초기에 발견해내는 것이 중요하다. 이에 본 논문에서는 데이터를 수집하여 폐암 예측 인공지능 모델을 만들고, 이를 실제로 우리가 현재 살고 있는 공장과 차가 많아, 공기의 질이 안좋은 인도네시아에서 우리 학교인 JIKS의 학생들과 인도네시아에 거주중인 사람들 총 32명을 대상으로 진행한 설문 결과를 통해 폐암을 예측한다. 실제 폐암 환자 309명의 데이터를 통해 딥러닝과 선형회귀를 활용하여 만든 폐암 예측 인공지능 프로그램중 더 정확도가 높았던 딥러닝 폐암 예측 AI모델이 약 93.55%의 정확도를 가지고 있었고, 오차는 0.18의 성능을 가지고 있다는 것을 확인할 수 있었다. 이 프로그램으로 폐암을 예측한 결과, 설문에 응해준 인도네시아의 32명의 사람들 중 26명이 폐암 의심 결과가 나왔다. 이 결과는 초기에 폐암 의심을 진단했다는 점에서 중요한 의미가 될수있었고, 또한 폐암 검사를 위해 굳이 기관지내시경이나 MRI 같은 것을 하지 않고 쉽게 폐암을 자가진단할 수 있다는 점에서 폐암에 대한 위험성을 각인 시켜주고, 이 병에 대한 인지율을 올릴수 있었다. 우리는 우리가 만든 폐암에 걸렸는지 예측하는 AI를 통해 시간이 없어, 병원에 가지 않더라도 집에서 몇초만에 쉽게 폐암 진단을 할 수 있는 시스템으로 발전시킬수있다.

1. 서론

1.1. 연구 배경

2. 본론

2.1. 이론적 배경

- 2.1.1. 폐암의 정의 및 증상
- 2.1.2. 폐암 진단 방법
- 2.1.3. 폐암의 원인
- 2.1.4. 폐암 환자 증가 배경
- 2.1.5. 폐암 발병 후 사망률
- 2.1.6. 로지스틱 회귀
- 2.1.7. 딥러닝
- 2.1.8. AI 모델에서 사용된 파라미터

2.2. 연구 진행

- 2.2.1. 데이터 수집
- 2.2.2. 폐암과 속성들 간의 상관관계
- 2.2.3. 폐암예측 로지스틱 회귀, 딥러닝 모델의 제작 과정
& 비교
- 2.2.4. 직스 학생 및 주변 성인 대상 설문
- 2.2.5. 설문 조사한 데이터를 우리가 만든 딥러닝 모델에
적용해보기

2.3. 연구 결과

3. 결론

3.1. 연구 요약 및 의의

4. 참고 문헌


1. 서론

1.1. 연구 배경

날이 지나면 지날수록, 국내와 해외에서는 점점 암의 환자 수가 늘어나고 있다. 국립암센터 통계 결과에 따르면 1999년에는 국내 암 환자수가 10만1847명이었던 것에 반해, 지난해인 2021년도에는 국내 암 환자수가 25만4718명으로 약 2.5배 넘게 증가한 것을 알수있다. 특히 그중에서도 점점 환자의 수가 꾸준히 늘고 있고, 가장 많은 사람들이 걸리는 폐암은 작년에는 국내에서 10만2843명의 환자가 있었는데, 올해는 11만376명으로 전년 대비 7.3%나 늘었는 것을 확인할 수 있다. 이 폐암은 다른 암과 마찬가지로 초기에는 증상이 눈에 띄지 않아 구분하기 어렵지만, 암은 우리나라 국민 10명중 4명이 걸릴 정도로 많은 사람들이 걸릴수 있는 질환이다. 통계청에서 발표한 자료에 따르면, 우리나라 국민의 전체 사망원인을 조사한 결과, 암으로 인한 사망 원인이 전체 원인중 1위로 기록될 정도로 많은 사람들이 걸리고, 위험한 것을 알 수 있다. 또한 우리나라뿐만 아니라 2021년 사망 원인 통계에 따르면 인구 10만명당 161.1명으로 세계에서 암으로 사망한 사람이 가장 많은 것을 알수 있었다. 이러한 암 중에서도 폐암의 사망률이 36.8명으로 가장 높았고, 그 뒤로 간암이 (20.0명), 대장암 (17.5명), 위암 (14.1명), 췌장암 (13.5명)이 뒤따랐다.



< 암의 종류별 비율 >



왼쪽의 그래프와 같이 암은 발견된 후 초기

1년에는 생존율이 82%로 높지만 점점 해가 지날수록 63%, 48%, 42%, 28%까지 떨어지게 되고, 결국 사망에 이르게 된다. 그렇기에 암은 초기에 빠르게 발병 여부를 확인하고 치료하는것이 중요하다. 하지만 이러한 폐암을 검사하기 위해선 흉부 X-선 촬영이나 전산화단층촬영(CT)를 통하여 폐암의 가능성을 영상학적으로 확인하며, 객담검사, 기관지내시경검사 (Bronchoscopy), 기관지내시경 초음파(EBUS), 경피적 미세침흡인세포검사 등으로 조직학적 확진을 시행하며 양전자방출단층촬영(PET), 뇌 자기공명영상(MRI) 등을 통해 폐암의 진행 정도(병기)를 판단해야하는데, 대부분의 사람들은 이러한 과정의 복잡성과 병원에 가기 귀찮은 것 때문에 폐암을 초기에 알아내지 못하고, 생활을 하다가 점점 암에 걸리고 시간이 지나 암을 치료하기 어려울 수준까지 왔을때서야 자신의 증상을 알아채고 병원에 방문하게 된다.

이에 본 논문에서는 앞서 언급했는 귀찮은 과정이나 절차를 거치지 않고, 또한 시간이 없어 병원에 가지 않아도 간단히 집에서 폐암인지 아닌지를 검사할수 있는 폐암 예측 인공지능 모델을 제안한다. 우리는 캐글(kaggle) 혹은 UCI machine learning data repository등의 사이트에서 309명의 폐암 환자 데이터를 수집하여, 그 환자의 성별, 나이, 흡연 여부, 손가락이 노란지 여부, 불안 발작, 동조 압력(동료한테 담배권유), 만성 질환, 피로, 알레르기, 숨쉴때 쉼쉼거림, 알코올 섭취, 기침, 호흡 곤란, 침 삼키기 어려움, 가슴 통증의 총 15개의 속성과 폐암의 양성, 음성 여부를 나타내는 각각 하나의 클래스를 포함하는 데이터를 통해 딥러닝과 선형회귀 모듈을 사용하여 총 두가지의 AI를 만들어줄 것이다. 그런 후, 그 두가지 AI 모듈중 우리의

데이터에 더 적합한 AI 모듈을 찾아, 그 AI 모듈로, 한국보다 공장과 차가 많아 공기가 나쁜 곳인 인도네시아에 살고 있는 자카르타 한국 국제학교(JIKS)의 학생들과 주변의 성인들을 대상으로 설문을 진행하여 폐암을 예측하고자 한다. 우리는 이 활동을 통해 사람들이 암을 초기에 발견하지 못해 사망하는 사례를 예방하고, 폐암을 별로 대수롭지 않게 여기던 사람들에게 경각심을 심어줄 수 있다. 또한, 폐암에 걸렸는지 예측하는 AI를 통해 병원에 가지 않더라도 집에서 쉽게 폐암 진단을 할 수 있는 시스템으로 발전 할 수 있다.

2. 본론

2.1. 이론적 배경

2.1.1. 폐암의 정의 및 증상

폐암은 국가암정보센터에 따르면, 폐에 생긴 악성 종양을 말하며, 폐 자체에서 발생하는 원발성 폐암의 종류는 암세포의 크기와 형태를 기준으로 폐암 가운데 80~85%를 차지하는 비소세포 폐암과 악성도가 높아 발견할 때에는 이미 다른 장기에 전이되어있는 소세포 폐암으로 구분된다.

폐암은 초기에는 증상이 전혀 없으며, 어느 정도 진행된 후에도 대부분 일반 감기와 비슷하게 기침이나 가래 같은 증상만 나타난다. 이후 점점 암종이 커지게 되면서 피가 섞인 가래나 객혈, 호흡곤란, 흉통등의 증상들이 유발되고, 점점 그 암종들이 후두신경이나 식도처럼 주위 조직을 침범하게 되면, 쉼 목소리나 연하 곤란, 상지 부종과 같은 증상들이 일어난다. 이후 암을 계속 놔두어 암이 전이되게 되면 뇌 기능 장애나 뇌 전이에 의한 두통,구토, 뼈의 통증까지 느껴지게 되고, 암세포에서 생성되는 물질에 의해서 식욕부진이나 발열 이상 호르몬과 같은 증상이 일어나게 된다.

2.1.2. 폐암 진단 방법

폐암을 진단하기 위해서는 흉부 X-선 촬영이나 전산화단층촬영(CT)를 통하여 폐암의 가능성을 영상학적으로 확인하며, 객담검사, 기관지내시경검사 (Bronchoscopy), 기관지내시경 초음파(EBUS), 경피적 미세침흡인세포검사 등으로 조직학적 확진을 시행하며 양전자방출단층촬영(PET), 뇌 자기공명영상(MRI) 등을 통해 폐암의 진행 정도(병기)를 판단한다.

2.1.3. 폐암의 원인



<서울 삼성병원 흡연 시작 연령과 폐암 사망률>

폐암의 대표적인 원인은 흡연으로, 폐암의 약 **70%**는 흡연에 의한 것으로 보고되어 있다. 일반적으로 흡연은 폐암 발생률을 **13배** 증가시킨다. 또한 간접흡연은 비흡연자가 흡연자와 같이 생활하거나 그 주위에 있으면서 자신의 의지와 무관하게 담배 연기를 흡입하는 것으로, 직접흡연과 마찬가지로 폐암을 일으킬 수 있다.


- 흡연 예방 방법

- 스포츠, 예술, 독서 등 담배 대신할 수 있는 취미, 즐거움을 가진다.
- 물, 주스 등의 수분을 많이 섭취하고 과일을 많이 먹는다.
- 담배가 없어서 손이 어색하면 연필, 가위, 고무줄, 빗자루 등 대용품을 만든다.
- 담배가 없어서 입이 심심하면 물을 마시거나 껌, 건어 등을 씹는다.
- 담배를 피고 싶으면 심호흡을 한다.
- 금연한 사람은 흡연하는 사람이나 흡연장소에 가까이 서지 말고 가능하면 피하도록 노력한다.


그리고 흡연외에도, 환경오염으로 인하여 공기 중의 발암 물질인 라돈과 같은 방사선 물질, 비산화 물질, 크롬 및 니켈 혼합물로 인하여 폐암이 걸리기도 한다. 특히 석면 노출시 폐암의 위험은 **4~5배** 증가하는 것으로 알려져 있다. 또한 기존의 폐질환으로 인하여 폐암이 발생하는 경우도 꽤 다발적인데, 만성폐쇄성질환이나 결핵, 규폐증과 같은 폐질환 또한 폐암 발병의 위험 요인중 하나가 될수도 있습니다. 마지막으로 유전적인 요인으로도 폐암에 걸릴수 있다. 폐암은 직접적으로 유전되는 질환은 아니지만, 가족 중에 폐암 환자가 있는 경우 폐암 발병의 위험은 **2~3배** 증가하고, 일부 환자에서 폐암 관련 유전자의 존재가 발견되어 폐암이 유전된다고 알려져있다. 따라서 정기검진을 주기적으로 받는 것이 중요하다.

2.1.4. 폐암의 정의 및 증상

최근 들어 폐암이 급증하는 이유는 물론 유전적인 원인도 있지만 그것보다는 흡연이나 환경오염으로 인하여 공기 중의 발암 물질을 들이마시는 것이 주요원인으로 꼽히고, 폐암은 담배를 많이 피는 남성들이 여성들에 비해 더 걸릴 확률이 높은 것으로 나타났다.



← 남녀 담배 피는 비율




← 연도별 폐암 환자수

그래프를 보면 알 수 있듯이 현대로 오면 올수록 계속해서 증가하고 있는 추세이다.

2.1.5. 폐암 발병 후 사망률

폐암은 앞에서 언급한 듯, 감기와 비슷한 증상을 가지고 있기 때문에 폐암을 발견했을 때 수술이 어려운 상태로 발견이 되는 경우가 많아 사망률이 높다.




← 파이썬의 matplotlib을 이용해 폐암의 생존율 그래프

폐암의 대부분을 차지하는 비소세포폐암의 경우 1기 5년 생존율이 80%, 2기의 경우 50-60%, 3기는 30%, 4기는 5%미만으로, 말기로 갈수록 생존율이 급격하게 떨어지는 것을 알 수 있었다.

2.1.6. 로지스틱 회귀


로지스틱 회귀란, 회귀를 사용하여 데이터가 어떤 범주에 속할 확률을 0에서 1사이 값으로 예측하고, 그 확률에 따라 가능성이 높은 범주에 속하는 것으로 분류해주는 지도 학습 알고리즘을 말한다. 로지스틱 회귀는 **Log Odds**를 이용한다. **Odds**란, 결과가 1일 확률/결과가 0일 확률으로 0부터 무한대까지의 값을 얻을 수 있다. 만약 폐암에 걸릴 확률이 0.7이면, $Odds = 0.7/0.3 = 2.333...$ 이다. 그리고 이 값에 log를 취한 것이 **Log Odds**이고, 앞의 예시에 적용해보면, $\log(2.333...) = 0.847$ 이 나온다. **Log Odds**함수는 $-\infty$ 부터 ∞ 까지의 값을 얻을 수 있다. 따라서, 결과가 0이나 1로 나와야 하기 때문에, **Log Odds**를 통해 나온 값을 0과 1사이의 값으로 변환해주기 위해서 **Sigmoid** 함수를 사용한다. **Sigmoid** 함수는 다음과 같다.



*Sigmoid*까지 적용하면 사건이 발생할 확률이 나오게 된다. 그 확률이 0.5보다 크면 1, 0.5보다 작으면 0으로 분류되는 것이다.

*Sigmoid*함수 이외에도 다중 분류류에 사용되는 **softmax**와 같은 다른 함수를 사용하기도 한다.


2.1.7. 딥러닝



딥러닝은 다층구조 형태의 인공 신경망을 기반으로 하는 머신러닝의 한 종류로, 다량의 데이터로부터 높은 수준의 추상화 모델을 구축할때 쓰는 기법이다. 이때, 컴퓨터가 사람처럼 스스로 학습할 수 있게 하기위해 인공 신경망을 구축해

학습하는데, 인공 신경망은 데이터 입력, 가중치 및 편중의 조합을 통해 인간의 뇌 속 신경망과 유사하게 인공적인 신경망을 만들어서 인간의 직감과 비슷하게 작용하도록 만든 기계학습 알고리즘이다.

- 가중치 : 딥러닝에서 다음 층으로 넘어가는 사이 사이에 값에 얼마나 곱해야 할지를 결정하는 것으로, 결과에 그 값이 얼마나 영향을 줄지 조절하는 매개변수이다.
- 편향 : 하나의 뉴런으로 입력된 모든 값을 다 더한 다음에 이 값에 더해주는 상수이다



이 데이터에 입력된 데이터의 샘플이 (0.05, 0.1)이고 타겟값이 (0.01, 0.99)라고 할 때, 은닉층은 가중치와 입력값의 곱에 편향을 더한 값을

받는다. 예를 들어, net_{h1} 은 $i1 \cdot w1 + i2 \cdot w2 = 0.05 \cdot 0.15 + 0.1 \cdot 0.2 = 0.0275$ 이다. 이 값이

Sigmoid

$$f(x) = \frac{1}{1 + e^{-x}}$$

들어오면, 0과 1사이의 값을 출력해주는 sigmoid

함수를 이용해 out를 구한다. net_{h1} 에 적용시키면,

out_{h1} 은 0.5069라는 값이 나온다. 동일한 방식으로 구한

out_{h2} 의 값은 0.6186이다. 또한 동일한 방법으로 다음 층의 값을 구하면, o1은 $net_{o1} =$

0.3817, $out_{o1} = 0.5943$, o2는 $net_{o2} = 0.4834$, $out_{o2} = 0.6186$ 이 나온다.


그리고 이 값을 원래의 타겟값과의 오차를 구해야한다. 오차는 오차제곱의 합, 즉

$$E_{total} = E_{o1} + E_{o2}$$

$$= \frac{1}{2} (target_{o1} - out_{o1})^2 + \frac{1}{2} (target_{o2} - out_{o2})^2$$

와 같은 식을 이용해 구한다. 따라서 out_{o1} 과 out_{o2} 의 오차는 0.2397이다. 이 오차의

최소값이 가중치로 편미분 했을 때 0이 되는 지점이다.



<기존의 8차원 그래프를 2차원의 그래프로 나타낸 것이다.>

편미분 했을 때의 값, 즉 기울기가 음수인지 양수인지에 따라 기울기를 0으로 만들기 위해 가중치를 옮겨줘야한다. 그리고 그 이동하는 정도를 학습률(learning rate)라고 한다.

가중치를 갱신할 때 새로운 가중치는 $wn^{+} = wn - a \frac{\partial E_{total}}{\partial wn}$ 와 같은 식으로 구한다.

(여기서 a 는 학습률이다.) 위의 식을 통해 가중치들을 갱신하준 후, 다시 E_{total} 을 확인하는 과정을 여러번 반복하면서 오차를 점점 줄여나가며 모델을 학습시킨다.

2.1.8. AI 모델에서 사용된 파라미터

sklearn - 기계학습 모델에서 사용되는 알고리즘이고, **sklearn** 즉 **scikit - learn**의 알고리즘 차트의 시트이다. **sklearn**을 이용하여 기계학습을 실행할 때, 우리의 분석하는 것에 대해 적절한 모델을 선택하는 것을 도와준다. **sklearn**의 분석에는 분류, 회귀, 클러스터링 등이 있는데, 우리는 **sklearn**에서 회귀중에서도 **Linear SVR**(선형회귀)을 하는데에 사용했다.

- **Ridge, Liner SVR** : 중소규모(10만건 미만)으로 설명 변수의 전부가 중요한 경우에 사용하는 회귀 분석 방법이다.
- **SVR(가우스 커널), Ensemble : Ridge 또는 Liner SVR**로 잘 분석되지 않는 경우 사용하며, 비선형적 회귀 분석 방법이다.

3. 클러스터링 - 전달된 데이터를 어떤 규칙에 따라 나누어준다. 선생이 없는 학습 클러스터링 문제를 해결해주는 알고리즘이다.

- **KMeans** : 몇 개의 클러스터를 분할할지, 사전에 정해둔 경우 추천하는 클러스터링 분석 방법이고, 대규모 데이터는 **MiniBatch**를 사용한다.
 - **MiniBatch** : 데이터를 나누면서 학습시키는 방법
- **스펙트럼 클러스터링(GMM)** : **KMeans**로 잘 분석되지 않는 경우에 이용하며, 비선형적인 클러스터링 분석 방법이다.
- **MeanShift, VBGMM** : 몇 개의 클러스터로 나눌지에 대해, 사전에 정할 수 없는 경우에 사용하는 클러스터링 분석 방법이다.

4. 기타 기능

- **차원감소** : 전달된 데이터의 차원 수가 많은 경우, 학습효율이 떨어지므로 차원을 감소시키는 전처리를 시행해줌
 - **PCA, 커널PCA, Isomap, SpectralEmbedding**
- **하이퍼 파라미터의 최적화** : 기계학습을 실행할 때, 학습 방법 등을 조정하는 수치를 하이퍼 파라미터라고 하는데, 이것을 계산하기 편하게 최적화시켜줌.
 - **그리드 서치, 크로스밸리테이션**

Adam(Adaptive Moment Estimation) : 딥러닝 최적화 기법중 하나로서 **Momentum**과 **RMSProp**의 장점을 결합해서 만든 알고리즘이다. 즉, 학습의 방향과 크기를 모두 개선한 기법으로 딥러닝에서 가장 많이 사용되는 최적화 기법이다.

- **momentum**의 한계점 : **Local Minimum**에 빠지기 쉬움, 안장점(**Saddle point**)을 벗어나지 못함.
- **RMSProp**의 장점 : 변수마다 적절한 학습률을 적용하여 효율적인 학습 가능, 보다 학습을 오래할 수 있음.

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla f(x_{t-1})$$

β_1 : Momentum의 지수이동평균 ≈ 0.9

$$g_t = \beta_2 g_{t-1} + (1 - \beta_2) (\nabla f(x_{t-1}))^2$$

β_2 : RMSProp의 지수이동평균 ≈ 0.999

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t}, \hat{g}_t = \frac{g_t}{1 - \beta_2^t}$$

$\hat{m}, \hat{g}$: 학습 초기 시 m_t, g_t 가 0이 되는 것을 방지하기 위한 보정 값


$$x_t = x_{t-1} - \frac{\eta}{\sqrt{\hat{g}_t + \epsilon}} \cdot \hat{m}_t$$

ϵ : 분모가 0이 되는 것을 방지하기 위한 작은 값 $\approx 10^{-8}$

η : 학습률 ≈ 0.001

1. 지수이동평균 : m_t 와 g_t 는 각각 Momentum과 RMSProp에서 사용한 수식과 동일한데, β 는 지수이동평균으로써 하이퍼파라미터이다. β_1 은 0.9가 가장 좋은 값이고, β_2 는 0.999가 가장 좋은 값이다. 지수이동평균은 예전 time step에서의 값은 적게 반영하고 최근 step의 값을 많이 반영하기 위해 해준다..
2. 편향 보정 : m_t, g_t 의 초기값이 0에 가까워지는 편향(bias)의 문제를 해결하기 위해 $\hat{m}, \hat{g}$ 을 만드는 과정을 편향 보정(bias correction)이라고 한다. 학습이 계속 진행되다 보면 $(1 - \beta_1)$ 와 $(1 - \beta_2)$ 는 거의 1에 가까워지기 때문에 $\hat{m}, \hat{g}$ 는 결국 m_t, g_t 와 같은 값이 된다.
3. 학습률 : 학습률은 어떠 비율만큼 파라미터를 업데이트할지 결정하는 값으로써 0과 1 사이의 값에서 나오는 하이퍼파라미터이다.
 - Adam 알고리즘에서 학습률은 0.001이 가장 좋은 설정 값이다.

sigmoid - 시그모이드는 활성화 함수의 한 종류로, 왼쪽의 그래프와 같이, 0과 1사이의



실수를 반환해주는 함수이다.

시그모이드 함수의 장점은, 출력 값의 범위가 0과 1 사이의 값이기

때문에 가중치를 갱신하는

과정에서 기울기 크면, 가중치가

너무 커져 발산하게 되는 오류인

기울기 폭주(Gradient Exploding)가


발생하지 않는다. 또한, 평범한 범주를 벗어난 값인 이상치가 들어온다고 하더라도 0이나 1에 수렴하기 때문에 이 문제도 해결된다. 하지만, 시그모이드 함수의 단점은 기울기 폭주와 반대되는 기울기 소실(**Gradient Vanishing**)이 발생할 수 있다는 것이다. 시그모이드 함수는 입력되는 값이 아무리 크더라도 0과 1사이의 좁은 범위의 값이 출력되기 때문에 곱할수록 점점 기울기가 작아지게 된다. 결국 기울기가 0에 수렴하면서 가중치가 거의 변하지 않게 되는 것이다.

따라서 시그모이드는 은닉층에서 시그모이드 함수를 사용하기에는 적합하지 않으며, 이진 분류를 해야하는 출력층에서만 사용하는 것이 적합하다.

relu - 은닉층에서 굉장히 많이 사용되는 활성화 함수이다. 은닉층에 어떤 활성화 함수를 써야할지 모르겠다 싶으면 **relu** 함수를 그냥 써도 될 정도로 은닉층에서 자주 사용되는 활성화 함수이다. 이 **relu** 함수는 정류된 선형 함수로 이루어져있는데, 이건 +,-가 반복되는 신호에서 - 흐름을 차단하여 음수일때는 0을 반환해주고, +가 나오면 그 값 자기 자신을 반환해준다. 동시에 **relu** 함수의 공식은 음수면 0, 양수면 자기 자신을 반환해주는 간단한 공식이기 때문에 경사하강법을 할 시 다른 활성화 함수에 비해 학습 속도가 매우 빠르다. 또한, 이전에 **Sigmoid** 함수에서 있던 기울기 소실 문제를 해결하였다.

- 기울기 소실 문제가 발생하지 않는 이유 : **relu** 함수는 양수는 그대로 음수는 0으로 반환하기 때문에 특정 양수 값에 수렴하지 않아, 출력값의 범위가 넓고 양수인 경우 자기 자신을 그대로 반환해 주기 때문에, 심층 신경망인 딥러닝에서 **sigmoid** 함수를

활성화 함수로 사용할 때 발생했던 문제인 기울기 소실 문제를 해결할 수 있다.



한계점 : 음수 값이 들어오는 경우 모두 **0**으로 반환하기 때문에 입력값이 음수인 경우 기울기도 전부 **0**으로 나오게 되고, 결국 가중치 업데이트가 안되는 현상이 발생하게 된다.

- **Binary classification**(이진분류) : 두 그룹중 하나로 분류하는 일반적인 머신러닝 기법이다.
- **binary cross entropy** : 출력층에서 **sigmoid** 함수를 사용하는 이진분류(Binary Classification)에서 이항 교차 엔트로피라고도 부르는 손실 함수이다.

비용함수 : 학습데이터에 존재하는 전체의 에러 정도를 의미함. 즉 오차, 모델이 설명하지 못하는 정도를 나타낸다. 그래서 이 파라미터의 최적 값은 비용함수의 값을 최소화하는 값이라고 볼 수 있다.

- 대표적인 비용함수에는 **MAE, MSE, RMSE**가 있다.

- $\frac{1}{N} \sum_i |y_i - \hat{y}_i|$ (mean absolute errors)
- $\frac{1}{N} \sum_i (y_i - \hat{y}_i)^2$ (**mean squared errors**)



정규방정식(Normal Equation) : 비용함수가 아래로 볼록한 2차 방정식 형태(convex form)인 경우, 미분해서 기울기가 0인 지점을 계산하면 비용함수를 최소화하는 지점을 찾을 수 있다. 하지만 대부분 실제 딥러닝의 비용함수는 위와 같은 형태로 복잡하게 나타나기에 이것을 사용하는 것은 어렵다.


경사하강법(Gradient Descent) : 앞서 얘기했던 것과 같이 대부분이 위와 같이 복잡한 형태로 나오기 때문에 딥러닝 비용함수에서는 Normal Equation을 사용할 수 없기 때문에 경사하강법을 사용해준다. 경사하강법은 한번에 최적의 비용함수 감소 지점을 찾을 수 없기 때문에, 임의의 지점에서 시작해서 값을 업데이트해 가면서 비용함수를 최소화하는 지점을 탐색하는 방법을 얘기한다.

하이퍼 파라미터 (Hyper Parameter) : 컴퓨터가 아니라 사람이 지정하는 파라미터를 말한다.

- 학습률(Learning Rate)

2.2. 연구 진행

2.2.1. 데이터 수집




먼저, 폐암 환자들의 데이터를 이용하여 인공지능을 학습시켜야 한다. 그러나 이것이 의료와 관련된 데이터였었기 때문에 데이터를 수집하는 것부터 생각보다 많은 제한이 있었고, 인공지능 학습을 시키기 위해서는 폐암환자의 데이터중 아무거나 사용을 하면 안되고, 어느 정도 일정한 형식에 맞춰진 데이터를 사용해야하기 때문에 이러한 데이터를 국내 사이트에서는 찾을 수 없어 사용할 수 없었다. 그래서 우리는 학습시키기 위한 데이터 세트들을 제공하는 캐글(kaggle) 혹은 UCI machine learning data repository등의 사이트에서 309명의 폐암 환자 데이터를 수집할 수 있었다.

우리가 수집한 환자 데이터에는 성별, 나이, 흡연 여부, 손가락이 노란지 여부, 불안 발작, 동조 압력(동료한테 담배권유), 만성 질환, 피로, 알레르기, 숨쉴때 쉼쉼거림,

알코올 섭취, 기침, 호흡 곤란, 침 삼키기 어려움, 가슴 통증의 총 15개의 속성과 폐암의 양성, 음성 여부를 나타내는 각각 하나의 클래스가 포함되어 있다.

2.2.2. 폐암과 속성들 간의 상관관계

폐암의 양성, 음성을 나타내는 클래스와 폐암과 관계가 있는 성별, 나이, 흡연 여부, 손가락이 노란지 여부, 불안 발작, 동조 압력(동료에게서의 담배 권유), 만성 질환, 피로, 알레르기, 쉼쉼거림, 알코올 섭취 여부, 기침, 호흡곤란, 침 삼키기 어려움, 가슴통증을 포함한 15가지 속성들의 상관관계를 알아보기 위하여 **seaborn** 라이브러리를 이용한다. **seaborn**을 사용하여 한 개의 클래스와 15개의 속성들을 데이터 분포 시각화 방식들 중 하나인 히트맵을 통해 나타내었다. 히트맵에서는 겹치는 부분의 숫자가 상대적으로 크거나 어둡고 진한 붉은색으로 표시되면 이것의 상관관계가 높다는 것을 의미하고, 숫자가 0이하이거나 색이 연한 노란색으로 표시되면 반비례하는 상관관계를 가진다는 뜻이다. 그와 반대로 겹치는 부분의 숫자가 0에 가까워지거나 연한 주황색으로 표시되면, 이것의 상관관계가 낮다는 것을 의미한다.



클래스와 속성들 간의 상관관계를 나타낸 히트맵이 16x16으로 구성된 그래프에서 폐암과 가장 상관관계가 있는 요인은 알레르기로 나타났는데, 알레르기에는 천식과 같은 만성 질환이 포함되어 있는데, 그 여러가지 만성 질환에서의 염증과 부기가 폐의 종양으로 이어지게 되고 이후 폐암에 걸리게 된다. 이에 잇따라서 2번째로 폐암과 연관이 있던 요인은 알코올 섭취 여부인데, 일단 알코올 자체가 발암 물질인데다가, 사람들중 몇몇이 술을 마시면서 담배를 함께 피기도 하고, 미국 루이지애나 대학 생리학과 교수인 Gregory J.Bagby 박사는 쥐를 통해 폐렴을 일으키는 폐렴구균인 ‘S. pneumoniae’가 알코올을 섭취한 쥐에게서 이 폐렴구균이 쥐의 폐로 더욱 빠르게 전이되어 지는 것을 확인 할 수 있었다고 한다. 그다음으로 3번째로 폐암과 연관이


있던 요인은 침삼키기 어려움이었는데, 침삼키기 어려운 것이 폐암의 증상중의 하나인데, 폐암에 걸리게 되면 객혈이나 인후통이 발생하게 되고, 이것이 침을 삼키기 어려운 것을 야기한다. 그리고 우리는 폐암뿐만 아니라 각각의 속성들 사이에도 연관성이 있는 것을 확인할 수 있다. 기침과 쌉쌉거림이 연관성이 있다는 것을 확인할수있는 것 뿐만 아니라, 흡연 여부가 가슴통증과 연관이 있는 등 우리는 이러한 히트맵을 통해 다양한 것들을 알수있다.

2.2.3. 폐암예측 로지스틱 회귀, 딥러닝 모델의 제작 과정 & 비교

이 모델의 개발 환경은 수정이 편리하고 자동저장 기능이 있는 구글 **colab**에서 이 프로그램을 만들게 되었다. 그리고 인공지능과 데이터 분석에 편리한 **pandas**, **numpy**, **tensorflow**, **keras**, **linear**와 같은 라이브러리들을 활용하기 위해 파이썬을 개발을 위한 프로그래밍 언어로 사용하였다. 또한 로지스틱 회귀와 딥러닝 모델 두개를 우리가 사전에 얻은 데이터를 통해 제작한 후, 두개의 정확성을 비교하여 우리의 데이터에 더 적합한 모델을 골라서 이 모델을 사용할 것이다.

로지스틱 회귀, 딥러닝 모델의 제작과정

1. 라이브러리 불러오기	구글 Colab 에 들어가서 머신러닝과 딥러닝, 데이터 처리에 필요한 matplotlib , numpy , tensorflow , pandas , keras , sklearn , linear 등의 라이브러리를 불러온다.
---------------	--

2. 데이터 불러오기 및 데이터셋 분리	<pre>#데이터 및 레이블 분리하기 lim = int(len(df)*0.7) #7:3 지점 저장 train_x = df.iloc[:lim, 0:15].to_numpy() test_x = df.iloc[lim:, 0:15].to_numpy() train_y = df.iloc[:lim, 15].to_numpy() test_y = df.iloc[lim:, 15].to_numpy()</pre> 우리가 수집한 데이터를 URL을 통해 csv 파일 형식으로 읽어온 뒤, 총 309명의 폐암 환자 데이터를 훈련 데이터인 train을 70%, 테스트 데이터인 test 30%로 분리한다. 7:3으로 분리하는 것이 가장 높은 정확도를 보임 
3. 로지스틱 회귀 모델 구성	LogisticRegression 모델로 로지스틱 회귀 모델을 구성한다. <pre>#로지스틱 회귀 학습하기 model = log_reg.fit(train_x, train_y)</pre> /usr/local/lib/python3.8/site-packages/sklearn/linear_model/_logistic.py:814: ConvergenceWarning: lbfgs failed to converge (status=1): STOP: TOTAL NO. of ITERATIONS REACHED LIMIT. Increase the number of iterations (max_iter) or scale the data as shown in: https://scikit-learn.org/stable/modules/preprocessing.html Please also refer to the documentation for alternative solver options: https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression n_iter_1 = _check_optimize_result 로지스틱 회귀는 데이터 묶음을 분류하기 위해 방정식을 계산하게 되는데 이 방정식은 가장 알맞은 매개변수의 집합을 찾는 것이다. 따라서 우리는 파이썬 머신러닝 라이브러리 SKLEARN을 불러와 로지스틱 회귀 모델을 만들어 학습한 후, 실제 환자의 폐암 여부를 이진 분류를 통해 0과 1로 나타내었다.
4. 로지스틱 회귀 학습	<pre>#로지스틱 회귀 학습결과 w = model.coef_ b = model.intercept_ print(w) print(b)</pre> <pre>[[0.00200053 0.04573753 0.80559779 0.62778395 0.5783787 0.84832202 1.22475447 1.48112671 1.54615032 0.7492707 1.05649184 0.8069011 0.11723387 1.16002273 0.52472941]] [-5.99026002]</pre> 앞에서 분리했는 데이터를 모델에 학습을 시킨 후, 가중치 w와 편향 b를 확인한 후 모델 테스트를 시킨다.

5. 학습 결과 및 정확도 확인

```
#모델 테스트
Y_prediction = model.predict(test_x).flatten()
for i in range(15):
    label = test_y[i]
    prediction = Y_prediction[i]
    print("실제 패암여부: {:.0f}, 학습후 예측 패암여부: {:.0f}".format(label, prediction))

실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 0, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1
실제 패암여부: 1, 학습후 예측 패암여부: 1

#모델 평가하기
y_pred = model.predict(test_x)
print("테스트 세트의 정확도 : {:.2f}".format(model.score(test_x, test_y)))

테스트 세트의 정확도 : 0.92
```

분리한 데이터로 로지스틱 회귀 모델을 테스트 해본 결과, 92%라는 정확도가 나왔다.

6. 딥러닝 모델 구성

```
#딥러닝 모델 구성하기
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense


model = Sequential()
model.add(Dense(30, input_dim=15, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
```

Sequential 모델로 딥러닝 모델을 구성했으며, 은닉층에 뉴런의 수를 30개로 지정했고, 활성화 함수로 ReLU를 사용했다. 또한, 출력층에는 Sigmoid를 활성화 함수로 사용하였다.

7. 딥러닝 모델 컴파일


```
#모델 컴파일
model.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
#loss='mse'
model.summary()

Model: "sequential"
-----
Layer (type)                Output Shape              Param #
-----
dense (Dense)                (None, 30)                480
dense_1 (Dense)              (None, 1)                 31
-----
Total params: 511
Trainable params: 511
Non-trainable params: 0
```



손실

함수에는 이진 분류에 사용되는 binary_crossentropy를 적용했으며, optimizer 즉,

	최적화 알고리즘은 adam을 사용하였다. 비용함수는 경사하강법(Gradient Descent)을 사용하였고, metrics에는 정확히 예측한 비율을 나타내는 accuracy를 이용했다.																																																																																																
8. 딥러닝 모델 학습	<pre>history = model.fit(train_x, train_y, epochs=100, batch_size=10, validation_split=0.25)</pre> Epoch 1/100 [=====] - 1s 14ms/step - loss: 0.4384 - accuracy: 0.8519 - val_loss: 0.2651 - val_accuracy: 0.9259 Epoch 2/100 [=====] - 0s 4ms/step - loss: 0.3938 - accuracy: 0.8590 - val_loss: 0.2382 - val_accuracy: 0.9259 Epoch 3/100 [=====] - 0s 5ms/step - loss: 0.3981 - accuracy: 0.8590 - val_loss: 0.2528 - val_accuracy: 0.9259 Epoch 4/100 [=====] - 0s 4ms/step - loss: 0.3736 - accuracy: 0.8590 - val_loss: 0.2339 - val_accuracy: 0.9259 Epoch 5/100 [=====] - 0s 5ms/step - loss: 0.3663 - accuracy: 0.8590 - val_loss: 0.2458 - val_accuracy: 0.9259 Epoch 6/100 [=====] - 0s 4ms/step - loss: 0.3618 - accuracy: 0.8590 - val_loss: 0.2438 - val_accuracy: 0.9259 Epoch 7/100 [=====] - 0s 4ms/step - loss: 0.3581 - accuracy: 0.8590 - val_loss: 0.2313 - val_accuracy: 0.9259 Epoch 8/100 [=====] - 0s 5ms/step - loss: 0.3488 - accuracy: 0.8590 - val_loss: 0.2187 - val_accuracy: 0.9259 Epoch 9/100 [=====] - 0s 4ms/step - loss: 0.3558 - accuracy: 0.8590 - val_loss: 0.2254 - val_accuracy: 0.9259 Epoch 10/100 [=====] - 0s 3ms/step - loss: 0.3254 - accuracy: 0.8590 - val_loss: 0.2157 - val_accuracy: 0.9259 Epoch 11/100 [=====] - 0s 3ms/step - loss: 0.3261 - accuracy: 0.8590 - val_loss: 0.2093 - val_accuracy: 0.9259 Epoch 12/100 [=====] - 0s 4ms/step - loss: 0.3258 - accuracy: 0.8590 - val_loss: 0.2162 - val_accuracy: 0.9259 Epoch 13/100 [=====] - 0s 4ms/step - loss: 0.3131 - accuracy: 0.8590 - val_loss: 0.2188 - val_accuracy: 0.9259 Epoch 14/100 [=====] - 0s 3ms/step - loss: 0.3168 - accuracy: 0.8590 - val_loss: 0.2086 - val_accuracy: 0.9259 Epoch 15/100 [=====] - 0s 3ms/step - loss: 0.3019 - accuracy: 0.8590 - val_loss: 0.2123 - val_accuracy: 0.9259 Epoch 16/100 [=====] - 0s 5ms/step - loss: 0.3008 - accuracy: 0.8590 - val_loss: 0.2242 - val_accuracy: 0.9259 Epoch 17/100 [=====] - 0s 4ms/step - loss: 0.2955 - accuracy: 0.8590 - val_loss: 0.2053 - val_accuracy: 0.9259 훈련 횟수(epochs)는 100회, batch_size는 10, validation_split은 0.25로 설정해 실행시켰다.																																																																																																
9. 검증 그래프 시각화	matplotlib을 이용해 훈련 횟수 대비 훈련 손실값(loss)과 검증 손실값(val_loss), 훈련 정확도(accuracy)와 검증 정확도(val_accuracy)를 나타내는 그래프를 만들었다.  <오차율(왼쪽)과 정확도(오른쪽) 시각화> ※첫번째 그래프에서 EPOCH(학습 횟수)가 늘어남에 따라 LOSS(실제 정답과 모델의 예측값의 차)가 줄어드는 것을 볼 수 있다.																																																																																																
10. 딥러닝 정확도 확인	분리한 데이터로 딥러닝 모델을 테스트 해본 결과, 92.47%라는 정확도가 나왔다.																																																																																																
11. 연관성이 낮은 데이터 제외하기	<pre>df2 = df.drop('동조 압력', axis = 1) df2.head()</pre><table><thead><tr><th>연령</th><th>성별</th><th>직업</th><th>소득</th><th>연령</th><th>성별</th><th>직업</th><th>소득</th><th>연령</th><th>성별</th><th>직업</th><th>소득</th><th>연령</th><th>성별</th><th>직업</th><th>소득</th></tr></thead><tbody><tr><td>0</td><td>남</td><td>학생</td><td>0</td><td>1</td><td>남</td><td>학생</td><td>0</td><td>1</td><td>남</td><td>학생</td><td>0</td><td>1</td><td>남</td><td>학생</td><td>0</td></tr><tr><td>1</td><td>남</td><td>학생</td><td>1</td><td>0</td><td>남</td><td>학생</td><td>1</td><td>1</td><td>남</td><td>학생</td><td>0</td><td>0</td><td>남</td><td>학생</td><td>1</td></tr><tr><td>0</td><td>여</td><td>학생</td><td>0</td><td>0</td><td>여</td><td>학생</td><td>0</td><td>0</td><td>여</td><td>학생</td><td>1</td><td>0</td><td>여</td><td>학생</td><td>0</td></tr><tr><td>0</td><td>여</td><td>학생</td><td>1</td><td>1</td><td>여</td><td>학생</td><td>0</td><td>0</td><td>여</td><td>학생</td><td>0</td><td>1</td><td>여</td><td>학생</td><td>0</td></tr><tr><td>0</td><td>여</td><td>학생</td><td>0</td><td>1</td><td>여</td><td>학생</td><td>0</td><td>1</td><td>여</td><td>학생</td><td>0</td><td>0</td><td>여</td><td>학생</td><td>0</td></tr></tbody></table> 우리가 사용한 데이터에서 폐암과 연관성이 낮은 데이터인 동조 압력을 drop으로 제거한 후, 다시 로지스틱회귀, 딥러닝 모델을 만들었다.	연령	성별	직업	소득	연령	성별	직업	소득	연령	성별	직업	소득	연령	성별	직업	소득	0	남	학생	0	1	남	학생	0	1	남	학생	0	1	남	학생	0	1	남	학생	1	0	남	학생	1	1	남	학생	0	0	남	학생	1	0	여	학생	0	0	여	학생	0	0	여	학생	1	0	여	학생	0	0	여	학생	1	1	여	학생	0	0	여	학생	0	1	여	학생	0	0	여	학생	0	1	여	학생	0	1	여	학생	0	0	여	학생	0
연령	성별	직업	소득	연령	성별	직업	소득	연령	성별	직업	소득	연령	성별	직업	소득																																																																																		
0	남	학생	0	1	남	학생	0	1	남	학생	0	1	남	학생	0																																																																																		
1	남	학생	1	0	남	학생	1	1	남	학생	0	0	남	학생	1																																																																																		
0	여	학생	0	0	여	학생	0	0	여	학생	1	0	여	학생	0																																																																																		
0	여	학생	1	1	여	학생	0	0	여	학생	0	1	여	학생	0																																																																																		
0	여	학생	0	1	여	학생	0	1	여	학생	0	0	여	학생	0																																																																																		

12. 제외한 데이터에서 데이터셋 분리	<pre>#데이터 및 레이블 분리하기 lim2 = int(len(df2)*0.7) #7:3 지점 저장 train_x2 = df2.iloc[:lim2, 0:14].to_numpy() test_x2 = df2.iloc[lim2:, 0:14].to_numpy() train_y2 = df2.iloc[:lim2, 14].to_numpy() test_y2 = df2.iloc[lim2:, 14].to_numpy()</pre> 총 309명의 폐암 환자 데이터중 동조 압력을 제외한 데이터를 훈련 데이터인 train을 70%, 테스트 데이터인 test 30%로 분리한다. 7:3으로 분리하는 것이 가장 높은 정확도를 보임
13. 제외한 데이터로 로지스틱 회귀 모델 구성	<pre>#로지스틱 회귀 모델 model2 = LogisticRegression(solver='lbfgs') model2.fit(train_x2, train_y2)</pre> 폐암과 연관성이 낮은 동조 압력을 제외한 데이터를 LogisticRegression 모델을 이용하여 로지스틱 회귀 모델을 구성한다.
14. 로지스틱 회귀 학습	앞에서 분리했는 데이터를 모델에 학습을 시킨 후, 테스트를 시킨다.
15. 학습 결과 및 정확도 확인	<pre>#모델 테스트 Y_prediction2 = model2.predict(test_x2).flatten() for i in range(15): label2 = test_y2[i] prediction2 = Y_prediction2[i] print("실제 폐암여부: {:.0f}, 학습후 예측 폐암여부: {:.0f}".format(label2, prediction2)) 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 0, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 실제 폐암여부: 1, 학습후 예측 폐암여부: 1 #모델 평가하기 y_pred2 = model2.predict(test_x2) print("테스트 세트의 정확도 : {:.2f}".format(model2.score(test_x2, test_y2))) 테스트 세트의 정확도 : 0.92</pre> 폐암과 연관성이 낮은 동조 압력을 제외한 데이터로 로지스틱 회귀 모델을 테스트 해본 결과, 여전히 92%라는 정확도가 나왔다.
16. 제외한 데이터로 딥러닝 모델 구성	<pre>#딥러닝 모델 구성하기 model2 = Sequential() model2.add(Dense(30, input_dim=14, activation='relu')) model2.add(Dense(1, activation='sigmoid'))</pre> Sequential 모델로 딥러닝 모델을 구성했으며, 은닉층에 뉴런의 수를 30개로 지정했고, 활성화 함수로 ReLU를 사용했다. 또한, 출력층에는 Sigmoid를 활성화 함수로 사용하였다.

17. 딥러닝 모델 컴파일

```
#모델 컴파일
model2.compile(loss='binary_crossentropy', optimizer='adam', metrics=['accuracy'])
model2.summary()
```

Model: "sequential_1"

Layer (type)	Output Shape	Param #
dense_2 (Dense)	(None, 30)	450
dense_3 (Dense)	(None, 1)	31

Trainable params: 481
Non-trainable params: 0

손실 함수에는 이진 분류에 사용되는 **binary_crossentropy**를 적용했으며, **optimizer** 즉, 최적화 알고리즘은 **adam**을 사용하였다. 그리고 **metrics**에는 정확히 예측한 비율을 나타내는 **accuracy**를 이용했다.

18. 딥러닝 모델 학습


```
#모델 학습
history = model2.fit(train_x2, train_y2, epochs=100, batch_size=10, validation_split=0.25)
```

Epoch 1/100
17/17 [=====] - 1s 15ms/step - loss: 6.6451 - accuracy: 0.1428 - val_loss: 3.3688 - val_accuracy: 0.6741
Epoch 2/100
17/17 [=====] - 0s 4ms/step - loss: 1.0482 - accuracy: 0.5105 - val_loss: 0.2671 - val_accuracy: 0.9259
Epoch 3/100
17/17 [=====] - 0s 4ms/step - loss: 0.4928 - accuracy: 0.8500 - val_loss: 0.2611 - val_accuracy: 0.9259
Epoch 4/100
17/17 [=====] - 0s 3ms/step - loss: 0.4732 - accuracy: 0.8500 - val_loss: 0.2639 - val_accuracy: 0.9259
Epoch 5/100
17/17 [=====] - 0s 4ms/step - loss: 0.3726 - accuracy: 0.8500 - val_loss: 0.2674 - val_accuracy: 0.9259
Epoch 6/100
17/17 [=====] - 0s 3ms/step - loss: 0.3741 - accuracy: 0.8500 - val_loss: 0.2691 - val_accuracy: 0.9259
Epoch 7/100
17/17 [=====] - 0s 5ms/step - loss: 0.3741 - accuracy: 0.8500 - val_loss: 0.2792 - val_accuracy: 0.9259
Epoch 8/100
17/17 [=====] - 0s 3ms/step - loss: 0.3629 - accuracy: 0.8500 - val_loss: 0.2699 - val_accuracy: 0.9259
Epoch 9/100
17/17 [=====] - 0s 4ms/step - loss: 0.3689 - accuracy: 0.8500 - val_loss: 0.2682 - val_accuracy: 0.9259
Epoch 10/100
17/17 [=====] - 0s 4ms/step - loss: 0.3592 - accuracy: 0.8500 - val_loss: 0.2784 - val_accuracy: 0.9259
Epoch 11/100
17/17 [=====] - 0s 4ms/step - loss: 0.3688 - accuracy: 0.8500 - val_loss: 0.2722 - val_accuracy: 0.9259
Epoch 12/100
17/17 [=====] - 0s 4ms/step - loss: 0.3599 - accuracy: 0.8500 - val_loss: 0.2556 - val_accuracy: 0.9259
Epoch 13/100
17/17 [=====] - 0s 5ms/step - loss: 0.3482 - accuracy: 0.8500 - val_loss: 0.2568 - val_accuracy: 0.9259
Epoch 14/100
17/17 [=====] - 0s 4ms/step - loss: 0.3457 - accuracy: 0.8500 - val_loss: 0.2627 - val_accuracy: 0.9259
Epoch 15/100
17/17 [=====] - 0s 3ms/step - loss: 0.3391 - accuracy: 0.8500 - val_loss: 0.2692 - val_accuracy: 0.9259
Epoch 16/100
17/17 [=====] - 0s 5ms/step - loss: 0.3428 - accuracy: 0.8500 - val_loss: 0.2576 - val_accuracy: 0.9259
Epoch 17/100
17/17 [=====] - 0s 5ms/step - loss: 0.3323 - accuracy: 0.8500 - val_loss: 0.2584 - val_accuracy: 0.9259
Epoch 18/100
17/17 [=====] - 0s 4ms/step - loss: 0.3312 - accuracy: 0.8500 - val_loss: 0.2471 - val_accuracy: 0.9259
Epoch 19/100
17/17 [=====] - 0s 4ms/step - loss: 0.3383 - accuracy: 0.8500 - val_loss: 0.2734 - val_accuracy: 0.9259
Epoch 20/100
17/17 [=====] - 0s 4ms/step - loss: 0.3383 - accuracy: 0.8500 - val_loss: 0.2734 - val_accuracy: 0.9259

훈련 횟수(epochs)는 100회, **batch_size**는 10, **validation_split**은 0.25로 설정해 실행시켰다.

19. 검증 그래프 시각화

matplotlib을 이용해 훈련 횟수 대비 훈련 손실값(**loss**)과 검증 손실값(**val_loss**), 훈련 정확도(**accuracy**)와 검증 정확도(**val_accuracy**)를 나타내는 그래프를 만들었다.



<오차율(왼쪽)과 정확도(오른쪽) 시각화>

※첫번째 그래프에서 **EPOCH**(학습 횟수)가 늘어남에 따라 **LOSS**(실제 정답과 모델의 예측값의 차)가 줄어드는 것을 볼 수 있다.

20. 딥러닝 정확도 확인

```
#모델 검증 평가
model2.evaluate(test_x2, test_y2)
```

3/3 [=====] - 0s 5ms/step - loss: 0.1869 - accuracy: 0.9355
[0.1869453340768814, 0.9354838728904724]

동조 압력을 제외한 딥러닝 모델을 테스트 해본 결과, 92.47%에서 93.55%라는 정확도까지 올랐다.

21. 우리 모델에 더 적합한

동조 압력을 제외한 후, 선형회귀 모델의 정확도는

모델 선정	92%, 딥러닝 모델 학습의 정확도는 93.55%인 것을 통해 우리의 데이터는 딥러닝 모델에 더 적합하다는 것을 알 수 있다.
-------	--

2.2.4. 직스 학생 및 주변 성인 대상 설문

앞서 만든 폐암 예측 프로그램을 통해 우리가 현재 살고 있는 인도네시아에서 살고 있는 한국인들 대상으로 실제 폐암을 예측해보기 위하여 설문을 진행해보았다. 설문은 구글에서 제공하는 설문지를 이용하였고, SNS나 온라인을 통해 이 설문을 배포했다. 설문의 질문은 총 15가지로 구성되어 있었고, 질문의 내용은 성별, 나이, 담배, 손가락이 노랗게 변색되었는지, 불안감, 담배 권유, 만성 질환, 피로, 알레르기, 음주, 질병으로 인한 것이 아닌 기침, 호흡곤란, 침을 삼키기 어려움, 가슴 통증에 대해 물어보고 있다. 이 질문의 내용은 데이터 수집과정에서 얻는 15개의 속성들을 물어보는 질문이다. 우리는 이 설문결과가 본 논문에 기재될 것임을 얘기하였고, 허락을 받고 이 결과를 논문에 사용하였다.

1. 본인의 성별을 선택해주세요. ☐ 남자 ☐ 여자	5. 불안감을 느끼시나요? ☐ 네 ☐ 아니요
2. 나이를 입력해주세요. 답답함 텍스트	6. 동료들에게 담배 권유를 받으신적이 있으신가요? ☐ 네 ☐ 아니요
3. 담배를 핀 적이있나요? ☐ 네 ☐ 아니요	7. 비만, 고혈압, 당뇨와 같은 만성 질환을 가지고 있으신가요? ☐ 네 ☐ 아니요
4. 손가락이나 손톱이 약간이라도 노랗게 변색되었나요? ☐ 네 ☐ 아니요	8. 피로를 자주 느끼시나요? ☐ 네 ☐ 아니요

9. 알레르기를 가지고 계신가요?

☐ 네
☐ 아니요

10. 술을 먹을 때 구역질이 나는 느낌이 나타나나요?

☐ 네
☐ 아니요

11. 술을 마시나요?

☐ 네
☐ 아니요

12. 장거리 운전 중 장시간 앉아 있을 때 불편함을 느끼시나요? (1주에 2번 이상)

☐ 네
☐ 아니요

13. 호흡곤란이 발생한 적이 있나요?

☐ 네
☐ 아니요

14. 음식을 삼키기 어렵다고 느낀 적이 있으신가요?


☐ 네
☐ 아니요

15. 가슴에 가끔 이유를 알수없는 통증이 느껴지시나요?


☐ 네
☐ 아니요

설문 통계 결과, 인도네시아내 자카르타, 땅그랑, 찌카랑에 거주하고 있는 한인들과 JIKS에 재학중인 학생들 총 32명의 사람들이 이 설문문에 응답해주었다. 이렇게 얻는 설문 결과 파일을 csv파일로 다운을 받은 후, 설문 응답에서 여자를 1, 남자를 0으로, 그리고 예를 1, 아니오를 0으로 변환하여 컴퓨터가 설문 응답 값을 읽을 수 있도록 만들어주었다.

1. 본인의 성별을 선택해주세요.
응답 31개




2. 나이를 입력해주세요.
응답 31개




3. 답배를 땀 적이있나요?
응답 31개




4. 손가락이나 손톱이 약간이라도 노랗게 변색되었나요?
응답 31개




5. 불안감을 느끼시나요?
응답 31개




6. 동료들에게 담배 권유를 받으신적이 있으신가요?
응답 30개




7. 비만, 당뇨, 천식과 같은 만성 질환을 가지고 있으신가요?
응답 31개




8. 피로를 자주 느끼시나요?
응답 31개




9. 알레르기를 가지고 계신가요?
응답 31개




10. 숨 쉴 때 '쌩쌩'거리는 소리가 나나요?
응답 31개



11. 술을 마시나요?
응답 31개




12. 감기와 같은 증상이 없이 가끔 기침을 하시나요? (1주에 2번이상)
응답 31개



13. 호흡곤란이 발생한 적이 있나요?


응답 31개



● 네
● 아니오

14. 침을 삼키기 어렵다고 느낀 적이 있으신가요?


응답 31개



● 네
● 아니오

15. 가슴에 가끔 이유를 알수없는 통증이 느껴지시나요?

응답 31개



● 네
● 아니오

폐암 예측 설문지(응답) ☆ 00 00											
파일 수정 보기 삽입 서식 데이터 도구 확장 프로그램 도움말											
100% 123 10 B I U A 100% 123 1											

<설문 조사에 응답 결과>

2.2.5. 설문 조사한 데이터를 우리가 만든 딥러닝 모델에

적용해보기

1. 데이터 불러오기

[illegible]

우리가 설문조사를 통해 수집한 데이터를 URL을 통해 csv 파일 형식으로 읽어왔다.

2. 데이터 전처리 과정

설문의 응답이 수집된 시간인 타임스탬프와 제외시켰을 때의 정확도가 더 높았던 동조압력이 있는 **column(열)**을 제외시켰다. 또한, 앞에서 학습에 쓰인 데이터와 동일하게 ‘네’를 1, ‘아니오’를 0, ‘남자’를 0, ‘여자’를 1로 변경했다. 그리고 나이에 ‘만’이나 ‘세’와 같은 문자가 포함된 데이터들은 모두 숫자로 고쳤다. 나이의 데이터들을 모두 숫자로 바꿨지만, 나이의 데이터 타입이 아직 **object**이기 때문에 **int**로 변경했다.

[illegible]

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 31 entries, 0 to 30
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  -
0   성별                  31 non-null    int64
1   나이                  31 non-null    int64
2   출연 여부            31 non-null    int64
3   손가락 색 변색       31 non-null    int64
4   불안 발작            31 non-null    int64
5   만성 질환            31 non-null    int64
6   피로                  31 non-null    int64
7   알레르기              31 non-null    int64
8   썩썩거림              31 non-null    int64
9   알코올 섭취 여부     31 non-null    int64
10  기침                  31 non-null    int64
11  호흡곤란              31 non-null    int64
12  침 삼키기 어려움     31 non-null    int64
13  가슴통증              31 non-null    int64
dtypes: int64(14)
memory usage: 3.5 KB
```

위의 사진을 보면, 데이터 타입이 전부 int로, 폐암 예측 모델이 적용시킬 수 있는 형태가 되었다.

3. AI모델에 적용하기

우선, 설문조사 결과 데이터셋인 `df_s`를 `numpy` 배열로 바꿨다. 그 후, `predict` 함수를 이용해 폐암에 걸렸을 확률을 구했다.

```
[191] test_x3 = df_s.to_numpy()
```

```
y_predict2 = model2.predict(test_x3)  
y_predict2
```

```
1/1 [-----] - 0s 19ms/step  
array([[0.93898046],  
       [0.9630957 ],  
       [0.608105  ],  
       [0.89691114],  
       [0.84592134],  
       [0.9962142 ],  
       [0.9842129 ],  
       [0.52664125],  
       [0.68651134],  
       [0.08429117],  
       [0.54292345],  
       [0.9967957 ],  
       [0.01886104],  
       [0.14906418],  
       [0.01249741],  
       [0.97164077],  
       [0.12486917],  
       [0.96248263],  
       [0.9926069 ],  
       [0.7637934 ],  
       [0.9902872 ],  
       [0.9727349 ],  
       [0.94289374],  
       [0.79821855],  
       [0.79096293],  
       [0.8542386 ],  
       [0.66813093],  
       [0.41034836],  
       [0.99166167],  
       [0.99600416],  
       [0.5340309 ],  
       [0.9661224 ]], dtype=float32)
```

그리고, 그 값이 0.5보다 크면 1, 크지 않으면 0으로 값이 바뀌도록했고, 결과는 다음과 같다.

```
[204] y_predict2 = np.where(y_predict2 > 0.5, 1, 0)  
y_predict2 = y_predict2.tolist()  
for i, L in enumerate(y_predict2):  
    print("{}번째 환자: {}".format(i+1, L))  
print("총합 위험 환자수/총 환자수: {}/{}".format(y_predict2.count([1]), len(y_predict2)))
```

```
1번째 환자: [1]  
2번째 환자: [1]  
3번째 환자: [1]  
4번째 환자: [1]  
5번째 환자: [1]  
6번째 환자: [1]  
7번째 환자: [1]  
8번째 환자: [1]  
9번째 환자: [1]  
10번째 환자: [0]  
11번째 환자: [1]  
12번째 환자: [1]  
13번째 환자: [0]  
14번째 환자: [0]  
15번째 환자: [0]  
16번째 환자: [1]  
17번째 환자: [0]  
18번째 환자: [1]  
19번째 환자: [1]  
20번째 환자: [1]  
21번째 환자: [1]  
22번째 환자: [1]  
23번째 환자: [1]  
24번째 환자: [1]  
25번째 환자: [1]  
26번째 환자: [1]  
27번째 환자: [1]  
28번째 환자: [0]  
29번째 환자: [1]  
30번째 환자: [1]  
31번째 환자: [1]  
32번째 환자: [1]  
총합 위험 환자수/총 환자수: 26/32
```

총 32명의 설문조사 응답자 중, 26명이 폐암에 걸릴 위험이 있다는 결과가 나왔다.

2.3. 연구 결과

총 309명의 폐암 환자들의 데이터를 가지고 폐암 예측 모델을 제작한 결과, 초기 동조 압력을 포함한 데이터를 통한 선형회귀에서는 정확도가 92%, 딥러닝에서는 정확도가 92.47%, 오차가 0.18이 나왔으나 폐암과 연관성이 떨어지는 데이터인 동조 압력을 제외한 후, 다시 선형회귀와 딥러닝 모델을 만들어 정확도를 확인해보니, 선형회귀는 동조압력을 제외하기전과 동일한 정확도인 92%로 정확도가 나타났으나 딥러닝에서는 정확도가 정확도는 93.55%이며, 오차는 0.16의 성능을 가지고 있는 폐암 예측 모델을 만들었고, 그중 가장 정확도가 높았던 동조 압력을 제외하고 시행한 딥러닝 AI모델을 최종적으로 폐암 예측 모델로 제작하였다. 그리고 우리는 공장이 많아 대기질이 안 좋은 인도네시아에 거주중인 한인들과 자카르타 한국 국제학교 학생들을 대상으로 설문조사를 진행했고, 총 32명이 설문에 응답해주었다. 설문 결과를 모델에 적용할 수 있도록 변형시킨 후 그 값들을 대입하여 폐암을 예측한 결과, 32인의 인도네시아 한인들 중 26명이 폐암 위험 결과가 나왔다. 그래서 우리는 이러한 폐암 위험 결과가 나온 사람들에게 폐암의 위험성을 다시 한번 각인 시켜주고, 폐암 예방 방법을 알려주었다. 그리고, 폐암과 15개의 속성들간의 상관관계를 히트맵으로 나타낸 결과는 알레르기, 알코올 섭취 여부, 그리고 침삼키기 어려움이 순서대로 높은 연관성을 보였다.

3. 본론

3.1. 연구 요약 및 의의

암은 우리나라 국민 10명중 4명이 걸릴 정도로 많은 사람들이 걸릴수 있는 질환이다. 통계청에서 발표한 자료에 따르면, 우리나라 국민의 전체 사망원인을 조사한 결과, 암으로 인한 사망 원인이 전체 원인중 1위로 기록될 정도로 많은 사람들이 걸리고, 위험한 것을 알 수 있다. 또한 우리나라뿐만 아니라 2021년 사망

원인 통계에 따르면 인구 10만명당 161.1명으로 세계에서 암으로 사망한 사람이 가장 많은 것을 알수 있었다. 이러한 암 중에서도 폐암의 사망률이 36.8명으로 가장 높았고, 그 뒤로 간암, 대장암, 위암, 췌장암등이 있었다. 또한 암은 시간이 지날수록 사망률이 높아지는데, 암이 발견되고 부터 초기 1년에는 생존율이 82%로 높지만 점점 해가 지날수록 점점 떨어져 5년이 지났을때는 28%까지 떨어지게 되고, 결국 사망에 이르게 된다. 그렇기에 암은 초기에 빠르게 발병 여부를 확인하고 치료하는것이 중요하다. 하지만 이러한 폐암을 검사하기 위해선 흉부 X-선 촬영이나 전산화단층촬영(CT)를 통하여 폐암의 가능성을 영상학적으로 확인하며, 객담검사, 기관지내시경검사 (Bronchoscopy), 기관지내시경 초음파(EBUS), 경피적 미세침흡인세포검사 등으로 조직학적 확진을 시행하며 양전자방출단층촬영(PET), 뇌 자기공명영상(MRI) 등을 통해 폐암의 진행 정도(병기)를 판단해야하는데, 대부분의 사람들은 이러한 과정의 복잡성과 병원에 가기 귀찮은 것 때문에 폐암을 초기에 알아내지 못하고, 생활을 하다가 점점 암에 걸리고 시간이 지나 암을 치료하기 어려울 수준까지 왔을때서야 자신의 증상을 알아채고 병원에 방문하게 된다. 그렇기 때문에 우리는 폐암 환자의 인지율을 높이고, 폐암을 초기에 알아내서 예방하자는 목적을 가지고, 자신이 폐암의 증상을 가지고 있을 때, 병원에 가거나 복잡한 절차를 하지 않고, 간편하게 자신의 폐암 의심을 예측해볼 수 있는 폐암 예측 모델을 제안했다. 이 연구는 인공지능을 학습시키기에는 조금 적은 309명의 폐암 환자 데이터를 가지고, 정확도가 93.55%, 오차는 0.18에 달하는 높은 정확성을 가진 AI모델을 제작했다. 또한 우리는 공장이 많아 대기질이 안 좋은 인도네시아에 거주중인 한인들과 자카르타 한국 국제학교 학생들을 대상으로 설문조사를 진행했고, 총 32명이 설문에 응답해주었는데, 이 설문 결과를 모델에 적용할 수 있도록 변형시킨 후 그 값들을 대입하여 폐암을 예측한 결과, 32인의 인도네시아 한인들 중 26명이 폐암 위험 결과가 나왔다. 그래서 우리는 이러한 폐암 위험 결과가 나온 사람들에게 폐암의 위험성을 다시 한번 각인 시켜주고, 폐암 예방 방법을 알려주었다. 또한, 우리가 수집한 폐암

환자 데이터를 통해 데이터를 분석하여 히트맵으로 이것을 나타냈을 때, 알레르기, 알코올 섭취 여부, 침 삼키기 어려움이 폐암과 가장 상관관계가 높았는 것을 알아낼수 있었다. 이러한 폐암 예측 AI 모델은 앞서 말했는 병원에 갈 수고와 귀찮고, 복잡한 검사 과정 없이 손쉽고 빠르게 자신의 폐암 의심 여부를 쉽게 진단 할수있다. 물론 이 AI모델의 정확도가 약 94%이기에 결과가 항상 정확하지는 않지만, 적어도 평소에 병원에 가기 귀찮고, 복잡한 절차 때문에 폐암에 대한 검사조차 받지 않았던 사람들이 간편히 몇초 만에 자신이 폐암 의심 환자인지를 알수있고, 여기서 폐암 의심 결과가 나오면, 바로 병원으로가서 더욱 정밀한 검사를 받을수 있다. 이러한 점에서 본 논문에서 제작한 폐암 예측 AI 모델은 앞으로 폐암 진단 프로그램으로 누구나 손쉽게 사용할수있고, 사람들의 폐암을 복잡한 절차와 병원에 가는 일 없이 최대한 빠르고 손쉽게 진단해보고, 예방할 수 있다는 점에서 이 AI 모델은 큰 의미를 가진다.

4. 참고문헌

기대수명: <https://www.index.go.kr/unify/idx-info.do?idxCd=8016>

사망원인통계:

https://kostat.go.kr/portal/korea/kor_nw/1/6/2/index.board?bmode=read&bSeq=&aSeq=420715&pageNo=1&rowNum=10&navCount=10&currPg=&searchInfo=&sTarget=title&sTxt=

알코올과 담배를 함께 하는 것에 대한 위험성 :

<https://www.ibric.org/myboard/read.php?Board=news&id=100462>

폐암 설명 :

<https://www.msdmanuals.com/ko/%ED%99%88/%ED%8F%90-%EB%B0%8F-%EA>

[%B8%B0%EB%8F%84-%EC%9E%A5%EC%95%A0/%ED%8F%90%EC%A2%85
%EC%96%91/%ED%8F%90%EC%95%94](#)

<https://www.cancer.go.kr/>

<http://chaga.co.kr/m/page.html?id=136#d>

폐암 데이터 링크: <https://www.kaggle.com/datasets/mysarahmadbhat/lung-cancer>

폐암 :

http://www.samsunghospital.com/dept/medical/healthSub02View.do?content_id=1774&DP_CODE=RT

폐암 삼성병원 :

http://www.samsunghospital.com/dept/medical/healthSub02View.do?content_id=80&cPage=3&DP_CODE=CIC&MENU_ID=004027017&ds_code=D0003490&main_content_id=744

sklearn 설명 : <https://engineer-mole.tistory.com/16>

딥러닝 비용함수 설명 :

<https://yeong-jin-data-blog.tistory.com/entry/%EB%94%A5%EB%9F%AC%EB%8B%9D-%EA%B0%9C%EB%85%90-%EB%B9%84%EC%9A%A9%ED%95%A8%EC%88%98-Cost-Function>

만성 폐쇄성 폐질환 :

<https://www.amc.seoul.kr/asan/healthinfo/disease/diseaseDetail.do?contentId=31528>

약국 신문 폐암 환자수 : <http://m.pharm21.com/news/articleView.html?idxno=70482>

직스,인도네시아사람들 설문조사 링크 :

https://docs.google.com/forms/d/e/1FAIpQLSfxslxJzyuMBPKZLKM87FvRk01uB62vqHHSXlekPrCbYUkxeg/viewform?usp=sf_link

만든 AI 링크 :

https://colab.research.google.com/drive/100JCmZGhEgig5pY9-NfA4Nw3ls_mJ6oU#scrollTo=3mOfa7CWpURX